

Benchmark: EAA với các sản phẩm Agent lập trình nhúng tốt nhất

Bốn lớp: tính năng · kiến trúc lõi · phi chức năng · UI/UX — đo ngày 05/09/2026

1. Báo cáo này đọc thế nào

Báo cáo so sản phẩm của đề án với những sản phẩm mạnh nhất hiện có trên thị trường Agent lập trình nhúng, theo bốn lớp: tính năng · kiến trúc lõi · phi chức năng · giao diện và trải nghiệm.

[canh_bao] Hai hạng bằng chứng, và chúng KHÔNG cộng lại thành điểm số. ĐO — con số lấy bằng cách chạy lệnh trên chính kho này ngày 05/09/2026; lệnh tái lập ghi ở §2. KHAI — thứ nhà cung cấp công bố, không chạy thử được. Một bảng xếp hạng dựng trên hai hạng bằng chứng khác nhau là bảng xếp hạng sai, và nó sai theo hướng có lợi cho người viết — tức là hướng khó tự phát hiện nhất.

Vì lý do ấy, báo cáo không cho một điểm tổng. Nó cho bốn bảng, và một danh sách việc phải làm ở §7 — trong đó có cả những việc lộ ra từ chính phép đo của ta, không phải từ so với ai.

Bốn sản phẩm được lấy làm mốc

Sản phẩm	Cốt lõi nó cựa vào	Vì sao lấy làm mốc
Embedder	Vòng kín trên silicon thật — quan sát phần cứng là kênh phản hồi CHÍNH	Gần đề án nhất về ý tưởng, và đi trước về bề rộng
Skilled AI Agents (arXiv 2603.19583)	Tri thức do NGƯỜI nén lại theo từng ngoại vi	Mốc duy nhất có ablation đo được
STM32 Sidekick · MCP Espressif	Thấm quyền trên tài liệu của hãng	Mốc về chất lượng nguồn tri thức
Parasoft · LDRA · QA Systems	Bằng chứng chứng nhận, truy vết hai chiều	Mốc về kỷ luật bằng chứng — gần ta nhất về triết lý

Bảng 1 — bốn mốc, mỗi mốc mạnh nhất ở một trục khác nhau

2. Số đo của EAA — và lệnh để kiểm lại

Mọi con số trong báo cáo lấy từ bảng này. Cột lệnh có đó để người đọc chạy lại chứ không phải để tin.
Đo ngày 05/09/2026.

Đại lượng	Giá trị đo được	Lệnh tái lập
Bộ test	2.656 bài, 0 đở, 7 phút 28	pytest -q
Tập ca kiểm thử	120 tập TC	ls tests/test_tc*.py wc -l
Hàm test	2.409	grep -rc '^def test' tests/*.py
Độ phủ mã phần lỗi	92% (composer · gates · orchestrator · state · vcs)	pytest --cov=eaa.orchestrator --cov=eaa.gates --cov=eaa.state --cov=eaa.vcs --cov=eaa.composer
Quy mô engine	89 tập, 48.230 dòng Python	find eaa -name '*.py' xargs wc -l
Quy mô bộ kiểm	136 tập, 36.565 dòng	find tests -name '*.py' xargs wc -l
Ranh giới engine	TC-38 xanh — 0 hăng số phần cứng trong eaa/	pytest tests/test_tc38_engine_purity.py
Lệnh CLI	56 lệnh cấp một, 103 lệnh đầy đủ	eaa --help
Công cụ Agent tự gọi	75 mục trong TOOLBOX	eaa capabilities
Cổng kiểm chứng	5 cổng (4 bắt buộc + regcheck)	OrchestratorConfig().required_gates
Lớp ngữ cảnh prompt	10 lớp, trần tổng 8.000 token, kiểm TRƯỚC khi gọi	eaa.llm.base.LAYER_BUDGETS
Lớp kết luận mang nhãn tin cậy	23 lớp	pytest tests/test_tc63_confidence_coverage.py
Số sai lệch thiết kế	178 mục, mỗi mục một bài kiểm canh	grep -c '^## SL-' docs/SAI_LECH_THIET_KE.md
Độ trễ lệnh đọc	status 0,57s · observe 0,66s · recall 0,66s · knowledge stale 0,76s	đo 3 lần, lấy nhanh nhất
Tính tất định	TC-15 chạy hai lần cho cùng 13/13 xanh, không cần khoá API	pytest tests/test_tc15_e2e.py (×2)
Thông báo lỗi nêu được lệnh phải gõ	150/182 — 82% (mốc trước khi sửa: 25/182 — 14%)	quét `raise CliError(` bằng phép đếm ngoặc cân; TC-145 canh
Lệnh thiếu dòng trợ giúp	0/103	duyet cây argparse
Mã thoát phân biệt	4 mã: 0 · 2 chờ gate · 3 hết vòng vá · 4 lỗi môi trường	eaa/__init__.py

Bảng 2 — 18 số đo, tất cả chạy được lại

3. Lớp 1 — Tính năng sản phẩm

Tiêu chí	EAA (ĐO)	Mốc mạnh nhất (KHAI)	Kết luận
Nối đất bằng tài liệu phần cứng	ĐO: trích đoạn qua G2; luật `// ref: `cường chế ở cổng tĩnh (TC-17); cổng `regcheck` kiểm giá trị löt vừa trường bit theo SVD/ATDF	Embedder KHAI: chỉ mục manual/datasheet/errata/SVD, trích dẫn từng giá trị	NGANG, và ta cưỡng chế mạnh hơn: thiếu trích dẫn là cổng ĐỎ. Không nguồn nào khảo sát được nêu phép kiểm ĐỎ RỘNG TRƯỜNG BIT
Bối cảnh bo từ sơ đồ nguyên lý	CHƯA CÓ. Hồ sơ phần cứng gõ tay	Embedder KHAI: đọc Altium/KiCad/Eagle/PADS, giải netlist ra chân, pull-up, địa chỉ bus	THIẾU RỖ. Và SL-125 là lần chính chỗ gõ tay ấy sai — giá phải trả là robot lao thẳng một phía
Bề rộng nền tảng	ĐO: 2 Platform Pack (avr, stm32), dùng chung engine — TC-47	Embedder KHAI: 500+ nền tảng, 13 hãng, 5.500+ ngoại vi	KHOẢNG CÁCH LỚN. Nhưng TC-47 đã chứng minh thêm pack không phải sửa engine — đây là công việc tuyến tính, không phải rào kiến trúc
Tri thức nén theo ngoại vi (kỹ năng)	MỘT PHẦN: `eaa/skills.py` rút kỹ năng QUY TRÌNH; chưa có kỹ năng PHẦN CỨNG	arXiv KHAI + ĐO: kỹ năng người soạn nâng ESP-IDF 26→40/42, Zephyr 24→39/42	THIẾU, và bài ấy đo được rằng nó đáng làm. Ghi chú quan trọng: kỹ năng do LLM TỰ SINH làm TỆ ĐI (Zephyr 24→19) và tốn gấp 15–30 lần token
Nạp firmware và đọc ngược xác minh	ĐO: `eaa/flash.py` preflight + đối chiếu băm ảnh; 26 lượt nạp có đọc ngược	Embedder KHAI: flash + serial smoke test	NGANG trở lên — ta đối chiếu băm ảnh, họ không nêu bước đọc ngược
Điều khiển máy đo, phiên gỡ lỗi tự động	CHƯA CÓ. `eaa/debugsession.py` dựng kế hoạch phiên, NGƯỜI chạy (mức T0)	Embedder KHAI: 30+ đầu dò, logic analyzer, dao động ký, đo công suất tương quan với thực thi	KHOẢNG CÁCH PHẦN CỨNG LỚN NHẤT. Tốn thiết bị, không chỉ tốn mã
Vòng đời tri thức: sửa tài liệu → truy ngược mã	ĐO: `eaa knowledge stale` hợp BA đường; chạy thật trên robot_balance trả 2 module, một cái bị cả ba đường bắt	Không nguồn nào khảo sát được nêu	**TA HƠN**
Trả lời câu hỏi từ kho tri thức đã duyệt	ĐO: `eaa recall`, hai tầng đồ thị → BM25, chỉ trả chunk qua G2 (TC-126)	Sidekick / MCP Espressif KHAI: tra cứu tài liệu chính chủ	NGANG về chức năng; khác về trách nhiệm — họ dặn người dùng tự đối chiếu, ta chỉ trả thứ đã có người đối chiếu

Bảng 3 — tính năng

Độc ra: ta ngang hoặc hơn ở phần TRI THỨC và KIỂM CHỨNG, và thua rõ ở phần CHẠM VÀO PHẦN CỨNG cùng BỀ RỘNG. Hai khoảng cách ấy không cùng độ khó — bề rộng là công việc tuyến tính đã có TC-47 chứng minh, còn máy đo thì tốn thiết bị.

4. Lớp 2 — Kiến trúc lõi

Tiêu chí	EAA (ĐO)	Mốc mạnh nhất (KHAI)	Kết luận
Ranh giới tăng cường chế bằng máy	ĐO: TC-38 quét mỗi commit — 0 hằng số phần cứng trong 89 tệp / 48.230 dòng engine. Thêm pack thứ hai không sửa một dòng engine (TC-47)	Không nguồn nào nêu một phép kiểm tự động cho ranh giới của chính mình	**TA HƠN.** Đây là tính chất KIẾN TRÚC duy nhất trong bảng có bài kiểm canh
Điểm dừng của con người	ĐO: 5 Human Gate; `TOOLBOX` là danh sách TÍNH trong Git và không chứa lệnh DUYỆT nào; merge đòi giấy phép neo vào BẮM NỘI DUNG (TC-01, TC-02)	Embedder KHAI: người duyệt kế hoạch, xem từng diff, và CHỌN hành động nào cần duyệt	KHÁC VỀ CHẤT. Của họ cấu hình được, tức tắt được. Của ta là bất biến — Agent KHÔNG CÓ ĐƯỜNG GỌI tới lệnh duyệt, chứ không phải được dặn dừng gọi
Kho tri thức nối tiếp, không ghi đề	ĐO: append-only + supersede ở cả 5 kho; hạ cấp một trích đoạn giữ NỘI DUNG nguyên từng byte, chỉ đổi siêu dữ liệu (TC-29, TC-132)	Không nguồn nào nêu	**TA HƠN.** Lịch sử truy vết chỉ có giá khi không ai được phép viết lại
Ngân sách ngữ cảnh cưỡng chế TRƯỚC khi gọi	ĐO: 10 lớp, trần tổng 8.000 token, `check_budget()` chạy trước mọi lượt gọi (TC-16). Đếm cả token SUY NGHĨ của model có tăng suy luận (SL-170)	arXiv KHAI: đo token vào trung bình theo cấu hình kỹ năng	TA HƠN ở chỗ CƯỜNG CHẾ: họ đo, ta chặn trước khi tiêu
Tính tất định và tái lập	ĐO: model ghim phiên bản, prompt stateless, bộ phát lại đọc nhật ký và CỐ Ý không bịa khi trượt bẫy; env_lock bẫy toolchain. TC-15 chạy hai lần cho cùng kết quả, không cần khoá API	Parasoft/LDRA KHAI: công cụ phải tất định mới *qualify* theo ISO 26262	**TA HƠN trong nhóm sinh mã. ** Đây là điều kiện chuẩn đòi, và ta thoả MỘT trong các điều kiện ấy — không phải 'đạt chuẩn'
Tự soi: hệ ghi lại chỗ chính nó sai	ĐO: 177 mục số sai lệch, mỗi mục một bài kiểm; `eaa deviations` quét mã ↔ tài liệu mỗi lần chạy (TC-60)	Không nguồn nào nêu	**TA HƠN.** Đây là dữ liệu gốc của phương pháp huấn luyện, và là thứ một sản phẩm thương mại không có lý do gì công bố
Bộ dò 'mã tự chỉnh cho vừa đồ đo'	ĐO: `eaa/instrument.py` ba dấu vết, dừng vòng vá và hỏi người (TC-131,	Không nguồn nào nêu	**TA HƠN.** 3/12 lần từ chối G3 của chính đề án là hạng lỗi này, và cả ba đi qua sạch bốn

	25 bài)		cổng
Đo độ nhạy của bài kiểm sinh ra	ĐO: `eaa/sensitivity.py` chạy bộ kiểm mới trên mã vừa bị đánh đỏ (TC-128)	Không benchmark nào trong khảo sát hỏi — cả ba đều đo pass/fail	**TA HƠN.** Một bài kiểm xanh chưa phải bằng chứng

Bảng 4 — kiến trúc

[ghi_nho] Đây là lớp EAA mạnh nhất, và sáu dòng 'TA HƠN' trong bảng không phải sáu ý tưởng rời. Chúng là MỘT: hệ thống phải biết, và phải nói ra, nó đáng tin tới đâu ở từng chỗ. Bốn mức tin cậy gắn vào 23 lớp kết luận là câu ấy viết thành mã.

5. Lớp 3 — Phi chức năng

Tiêu chí	EAA (ĐO)	Mốc mạnh nhất (KHAI)	Kết luận
Độ phủ mã phần lõi	ĐO: 92% trên composer/gates/orchestrator/state/vcs. Yêu cầu của đề án là $\geq 80\%$	Không nguồn nào công bố	VƯỢT yêu cầu tự đặt. Không so được với ai vì không ai công bố
Thời gian chạy bộ kiểm	ĐO: 2.656 bài trong 7 phút 28 trên một máy để bàn	Không nguồn nào công bố	Đủ nhanh để chạy mỗi commit — và nó ĐANG chạy mỗi commit
Độ trễ tương tác	ĐO: lệnh đọc 0,25–0,79 giây	Không nguồn nào công bố	Đủ nhanh cho vòng hỏi–đáp. Lượt SINH MÃ thì do mô hình quyết định, không phải do ta
Bảo mật khoá API	ĐO: khoá chỉ qua biến môi trường; TC-14 canh khoá không lọt vào log, ngoại lệ, `repr`, hay nhật ký lời gọi	Embedder KHAI: SOC 2 Type II, ISO 27001, GDPR, triển khai air-gapped	KHÁC HẠNG — của họ là chứng nhận TỔ CHỨC, của ta là tính chất PHẦN MỀM có test. Hai thứ không thay nhau được, và ta không có cái thứ nhất
Chạy ngoại tuyến	ĐO: `EAA_NO_NET=1` cắt mọi lối ra mạng; MockLLM và bộ phát lại chạy không cần khoá	Embedder KHAI: triển khai on-prem và air-gapped	MỘT PHẦN. Ta chạy được không mạng, nhưng lượt gọi mô hình THẬT vẫn ra API ngoài. Air-gapped đòi mô hình chạy tại chỗ
Chi phí mỗi lượt gọi	ĐO: `llm_calls.jsonl` ghi token vào/ra từng lượt; `TokenBudget` chặn trước	arXiv KHAI: token vào trung bình theo cấu hình	NGANG trở lên
Chạy nhiều phiên trên cùng một bo	CHƯA CÓ	Embedder KHAI: trọng tài phần cứng, chặn hai phiên cùng lái một bo	THIẾU, và nó thành lỗi thật ngay khi có người thứ hai. Rẻ: một khoá tệp trên cổng nối tiếp

Bảng 5 — phi chức năng

Chỗ phải nói thẳng: chứng nhận tổ chức (SOC 2, ISO 27001) là thứ ta KHÔNG có và cũng không phải tính năng phần mềm để mà làm. Nó là chứng nhận của một doanh nghiệp. Ghi vào đây để không ai nhầm nó là một khoảng trống kỹ thuật cần lấp.

6. Lớp 4 — Giao diện và trải nghiệm

Tiêu chí	EAA (ĐO)	Mốc mạnh nhất (KHAI)	Kết luận
Mặt tiếp xúc chính	ĐO: CLI 56 lệnh cấp một + tăng hội thoại tiếng Việt `eaa chat`	Embedder KHAI: extension VS Code là mặt chính, kèm CLI và daemon cho terminal/GitHub/Slack/CI. Espressif KHAI:	THIẾU IDE. Đây là chỗ kỹ sư nhúng ngồi cả ngày. Không đụng lỗi: một lớp mỏng gọi CLI

		Copilot trong IDE của hãng	
Trợ giúp và khám phá	ĐO: 0/103 lệnh thiếu dòng trợ giúp; `eaa capabilities` bày 4 tầng năng lực	Không nguồn nào công bố	TỐT, và đo được
Chất lượng thông báo lỗi	ĐO: 150/182 thông báo lỗi (82%) nói được VIỆC PHẢI LÀM. Mốc trước khi sửa là 25/182 — 14%	Không nguồn nào công bố	**ĐÃ SỬA (SL-178).** Bảng `GOI_Y_KHI_HONG` gắn ở `main()`, nên lỗi ném từ hàm phụ trợ vẫn nhận đúng gợi ý của lệnh đang chạy. TC-145 đối chiếu bảng với cây lệnh thật, hai chiều — một gợi ý trở vào lệnh đã bị xóa là đỏ
Nói ra mức tin cậy của mỗi câu trả lời	ĐO: 23 lớp kết luận mang một trong bốn mức ĐẢ KIỂM / SUY RA / GIẢ ĐỊNH / KHÔNG KIỂM ĐƯỢC; TC-63 canh không lớp nào quên	Sidekick KHAI ngược lại: dẫn người dùng TỰ đối chiếu tài liệu gốc	**TA HƠN.** Nhưng nói cho đúng: 23 LỚP KẾT LUẬN, không phải mọi dòng đều ra
Mã thoát cho tự động hoá	ĐO: 4 mã phân biệt — 0 · 2 chờ gate · 3 hết vòng vá · 4 lỗi mỗi trường	Embedder KHAI: CLI và daemon cho CI	NGANG. Bốn mã ấy là thứ một pipeline CI cần
Ngôn ngữ	ĐO: toàn bộ giao diện, thông báo và tài liệu bằng tiếng Việt	Sidekick KHAI: hỏi được nhiều thứ tiếng, giao diện chính tiếng Anh	KHÁC BIỆT CỐ CHỦ ĐÍCH cho bối cảnh đề án; đồng thời là rào nếu muốn ra ngoài — phải nói ra chứ không giấu

Bảng 6 — UI/UX

Phép đo tự chỉ ra một điểm yếu mà so sánh với đối thủ không chỉ ra được — và bản này phải đánh chính chính nó. Bản trước công bố 36% (40/112); con số ấy SAI vì biểu thức quét chỉ bắt được một dạng viết `raise CliError`, nên nó đếm thiếu cả tử lẫn mẫu. Quét lại bằng phép đếm ngược cân cho mốc thật: 25/182 — 14%. Sai số của phép đo chứ không phải của sản phẩm, nhưng nó đã được in ra nên nó được sửa công khai chứ không thay lặng lẽ. Đã sửa (SL-178): 150/182 — 82%. Cách sửa đáng nói hơn con số. Không viết gợi ý vào 182 chuỗi — mỗi chuỗi như vậy là một bản sao của cây lệnh, và nó lệch khỏi cây lệnh ngay lần đầu ai đó đổi tên một lệnh, mà không gì bắt được. Gom vào một bảng thì bắt được: TC-145 đối chiếu bảng gợi ý với cây lệnh dựng từ `argparse`, hai chiều. 82% là CẬN DƯỚI. 32 chỗ còn lại nằm trong hàm phụ trợ mà phép quy về lệnh không với tới; lúc chạy thật chúng vẫn có gợi ý, vì bảng gắn ở `main()` — nơi biết người dùng vừa gõ lệnh nào. Báo cả hai con số.

7. Việc phải làm — thẳng thắn

Ưu tiên	Việc	Vì sao	Xong thì đo bằng gì
1 · XONG	Sửa thông báo lỗi: nâng tỉ lệ nói được việc phải làm lên $\geq 80\%$ — ĐẠT 82%	Điểm yếu UI/UX ĐO ĐƯỢC duy nhất trong bảng, và là chỗ rẻ nhất. Đo lại bằng phép quét đúng thì mốc thật là 14%, không phải 36% như bản trước công bố — bản này đỉnh chính	ĐÃ ĐO: $150/182 = 82\%$. TC-145 (11 bài, 4 đợt biến đều bị bắt) canh cả tỉ lệ lẫn tính đúng của từng gợi ý. Xem SL-178
2 · Cao	Bộ nhiệm vụ cho thước đo, trên ≥ 2 Platform Pack	Cái thước đã có (GĐ2) nhưng chưa đo gì. Bốn trục đang báo CHƯA ĐO ĐƯỢC — và một đóng góp không có số là một lời khai	‘eaa report bench’ ra số thật cho cả bốn trục
3 · Cao	Đo ngược lịch sử dự án bằng bốn bộ dò	37 commit và 12 lượt chuyển module đã nằm trong Git. Không tốn token API. Nếu bốn bộ dò tìm lại được các lỗi đã biết thì đó là bằng chứng hồi cứu; nếu bỏ sót thì đó là phát hiện còn giá trị hơn	Bảng số cho Chương 3, và danh sách lỗi bộ dò bỏ sót
4 · Vừa	Kỹ năng phần cứng theo ngoại vi, duyệt qua G2	Chỗ DUY NHẤT bài arXiv đo được là nâng kết quả lên gần trần. Và nó chặn hạng lỗi đã làm robot ngã: mã đúng mọi dòng, sai ở THỨ TỰ	So pass@k trước/sau khi bật lớp kỹ năng, trên cùng bộ nhiệm vụ
5 · Vừa	Đọc netlist và ĐỐI CHIẾU với hồ sơ phần cứng ở G1	Bắt hạng lỗi SL-125 — hồ sơ gõ tay lệch với mạch thật	Số chỗ lệch tìm được trên dự án thật
6 · Vừa	Trọng tài phần cứng: khoá cổng nối tiếp	Thành lỗi thật ngay khi có người thứ hai chạy cùng bo	Hai phiên đồng thời: phiên thứ hai phải bị chặn với thông báo rõ
7 · Vừa	Lớp mỏng tích hợp IDE	Mặt tiếp xúc mà kỹ sư nhúng ngồi trong đó cả ngày. Không đụng lỗi	Số bước từ mở IDE tới lượt sinh đầu tiên
8 · Thấp	Điều khiển máy đo và phiên gỡ lỗi tự động	Khoảng cách phần cứng lớn nhất, nhưng tốn THIẾT BỊ chứ không chỉ tốn mã. Và chỉ có nghĩa khi đã có thước để chứng minh nó cải thiện được gì	Số kịch bản chẩn đoán chạy được không cần người cầm que đo

Bảng 7 — tám việc, xếp theo giá trị trên chi phí

Ba việc đầu đều là việc BIẾN LỜI KHAI THÀNH SỐ, không phải việc thêm tính năng. Đó là chỗ đề án đang yếu nhất: sáu năng lực không ai có, nhưng chưa có số nào chứng minh chúng cải thiện được gì.

Điều kiện dừng

- Bốn trục đo mới có số liệu trên ít nhất hai Platform Pack.
- ~~Tỉ lệ thông báo lỗi nói được việc phải làm đạt $\geq 80\%$, có bài kiểm canh.~~ XONG — 82%, TC-145.
- Bốn bộ dò chạy lại được trên 12 lượt chuyển module của lịch sử dự án, và kết quả — dù tìm ra hay bỏ sót — được ghi vào sổ sai lệch.

Đến đó thì câu “Agent này tốt hơn” thôi là một lời khai; nó thành một bảng số mà người khác kiểm lại được.

8. Điều báo cáo này KHÔNG chứng minh

- Không chạy thử sản phẩm thương mại nào. Cột KHAI là thứ nhà cung cấp công bố, và khoảng cách giữa “khai có” với “đo được” là khoảng cách không đo được từ bên ngoài.
- Không so chất lượng mã sinh ra của các bên. Muốn so thì phải có bộ nhiệm vụ chung chạy trên cùng phần cứng — chính là việc số 2 ở §7.
- Không khẳng định đề án “đạt chuẩn ISO 26262”. Nó thoả MỘT điều kiện mà chuẩn đòi — tính tất định của công cụ — và chỉ thế.